

SB Part B

Free Exercise 1

$$D_1 = [1, 0, 1, 1, 0]$$

$$D_2 = [0, 1, 1, 1, 0]$$

$$D_3 = [1, 0, 0, 1, 1]$$

Ex 2: $TF(cat, D_1) = \frac{1}{3}$

$$TF(cat, D_1) = \frac{1}{3}$$

$$TF(fish, D_1) = \frac{1}{3}$$

$$\sum TF(A, D_1) = \frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$$

Ex 3

Ta có: $IDF(x) = \log\left(\frac{N}{DF(x)}\right)$

$$idf(cat) = \log\left(\frac{2}{\frac{3}{2}}\right) = 0,406$$

$$idf(dog) = \log(1) = 1,099$$

$$idf(cat) = \log\left(\frac{1}{2}\right) = 0,406$$

$$idf(fish) = \log\left(\frac{1}{1}\right) = 0$$

$$idf(likes) = \log(3) = 1,099$$

$\Rightarrow$ fish có IDF thấp nhất vì fish đều có mặt ở mọi tài liệu vì vậy độ hiếm của nó khá thấp nhất.

Ex 4

$$TF-idf(cat, D_1) = \frac{1}{3} \cdot 0,406 = 0,135$$



$$\text{idf}(\text{cat}, D_1) = \frac{1}{\frac{0.406}{1.099}} \approx 2.1352$$

$$\text{idf}(\text{fish}, D_1) = \frac{1}{1} \cdot 0 = 0$$

$\Rightarrow$ "fish" vẫn xuất hiện trong D_1 , $\text{tf}(\text{fish}, D_1) = \frac{1}{1}$ nhưng vì "fish" có mặt ở cả 1 tài liệu nên $\text{IDF} = 0$ nghĩa là "fish" sẽ không giúp phân biệt tài liệu có tài liệu khác trong corpus.

Ex 5:

$$x = [1, 1, 1]$$

$$y = [1, 1, 0]$$

$$\cos(x, y) = \frac{x \cdot y}{\|x\|_2 \|y\|_2}$$

$$\|x\|_2 \|y\|_2$$

$$= \frac{(1 \cdot 1) + (1 \cdot 1) + (1 \cdot 0)}{\sqrt{1} \cdot \sqrt{2}} = \frac{2}{\sqrt{2}} = \sqrt{2} \approx 0.8115$$

$\Rightarrow$ Trả lời câu hỏi: Nó không bằng $\frac{2}{3}$ vì $\frac{2}{3}$ chỉ là cách đoán. Còn ở đây cosine tính xem 2 vector có gần hay xa nhau như nào đâu. Nếu gần 1 thì 2 vector sẽ giống nhau hơn; Ngược lại gần 0 thì càng khác nhau.

Ex 6

1. D_1 có similarity cao nhất vì nó dùng D_1 hơn hẳn trong k khớp với câu hỏi tìm kiếm
2. D_1 có similarity thấp nhất vì D_1 nó sẽ xử lý ngôn ngữ tự nhiên và không có từ nào trùng với câu hỏi tìm kiếm.
3. "medical" và "image" có IDF thấp nhất vì mỗi từ đều xuất hiện trong 2 tài liệu D_1 và D_2 (nhieu nhất).
4. Nếu chỉ dùng count vector thì thứ tự được vẫn là $D_1 \rightarrow D_2 \rightarrow D_3$. Vì
 - + D_1 trong tất cả các từ với câu tìm kiếm
 - + D_2 chỉ trong 2 từ là "medical" và "image"
 - + D_3 thì không trong từ nào.

6. Part C:

Predictions 1:

Nếu có ~~khung~~ corpus có 50000 documents,
 vocab sẽ có ~~khung~~ 200000 unique terms. Vì 50k docs
 document là con số khá lớn nên sẽ có nhiều
 chủ đề mà mỗi chủ đề lại chứa nhiều unique
 terms khác nhau.

Prediction 2:

Mô hình TF-IDF sẽ sparse vì chỉ mỗi tài liệu sẽ chỉ chứa một số từ nhất định trong vocab của toàn bộ tài liệu. Vì vậy, tỉ lệ 0 hàng 0 có thể rất cao, có thể lên đến gần 90%.

Prediction 2:

Với mỗi query bất kỳ, các tài liệu được đánh giá kết quả tìm kiếm không nhất thiết là các tài liệu gần nghĩa vì TF-IDF và cosine similarity chủ yếu dựa vào từ xuất hiện giống nhau.

-) Vì vậy mỗi tài liệu cần phải từ khóa với query sẽ được xếp cao, cho dù có thể mỗi nội dung không phải hoàn toàn.
- Ngược lại, một tài liệu mang ý nghĩa chuẩn nhưng có thể bị xếp thấp do nó chứa các từ gần nghĩa.