

Ex 1

vec cat : [the, cat, dog, cat, likes, fish, milk, ...

cat = [2, 0, 0, 1, 1, 0, 0, 0]

dog = [0, 0, 0, 1, 1, 0, 0, 0]

cats = [0, 1, 1, 0, 0, 2, 0, 0]

likes = [0, 1, 1, 0, 0, 0, 1, 1]

Ex 2:

$x = [1, 2, 1]$

$y = [2, 9, 2]$

$$\cos(x, y) = \frac{2+8+2}{\sqrt{6} \cdot \sqrt{49}} = 1$$

Đáp lại câu hỏi: Cosine similarity = 1 nghĩa là hai vector cũng hướng hoàn toàn, dù độ dài của chúng có thể khác nhau.

Bài 3:

Dự đoán: từ "physician" và từ "dễ gần" "doctor" hơn vì có thể thấy hai từ đều được hiểu là bác sĩ.

$$\cos(\text{doctor}, \text{physician}) = \frac{1,14}{\sqrt{1,14} \cdot \sqrt{1,14}} = 0,997$$

$$\cos(\text{doctor}, \text{banana}) = \frac{-0.14}{\sqrt{0.14^2 + 0.14^2}} = -0.1411$$

$\Rightarrow$ physician gần doctor hơn rất nhiều

Bài 4

1. Biểu diễn 10.000 chiều nhưng chỉ có 30 giá trị khác 0 là sparse representation. Vì phần lớn phần tử của vector là 0.

2. Embedding 300 chiều và hầu hết giá trị đều khác 0. là dense representation.

3. Biểu diễn dense có thể thuận lợi cho semantic similarity vì:

- Nó biểu diễn thông tin ngữ cảnh và nghĩa của từ trong một không gian vector có số chiều nhỏ hơn.
- Những từ xuất hiện trong các ngữ cảnh tương tự thường có các vector dense gần nhau.

$\Rightarrow$ Có thể dùng cosine similarity để đo mức độ tương đồng ngữ nghĩa giữa các từ hiệu quả hơn so với biểu diễn sparse dựa trên số lần xuất hiện.

4. Biểu diễn dense có chắc chắn tốt hơn biểu diễn sparse trong mọi bài toán không? không

h⁻ :

- Dense phù hợp với bài toán cần do semantic similarity và giảm số chiều biểu diễn, trong khi sparse có thể dễ giải thích hơn và phù hợp với các bài toán cần thông tin về sự xuất hiện hoặc tần suất chính xác của từ. Vì vậy, việc lựa chọn sparse hay dense phụ thuộc vào bài toán cụ thể.

9 Prediction trước experiment.

Prediction 1: "doctor" và "physician" sẽ có similarity cao nhất. "hospital" cũng khá gần nghĩa với hai từ này.

Reasoning: "doctor" và "physician" là hai từ rất gần có nghĩa là "bác sĩ" còn "hospital" liên quan vì hơn bác sĩ thường sẽ làm ở bệnh viện.

Prediction 2: Confidence: X.0 Cao

Prediction 2: Có, similarity có thể thay đổi

Reason: Khi context window lớn hơn, mỗi từ sẽ được biểu diễn dựa trên nhiều từ xung quanh hơn. Điều này làm thay đổi vector context của từ và do đó có thể làm thay đổi cosine

similarity. Window lớn hơn có thể thu được nhiều thông tin ngữ nghĩa hơn, nhưng cũng có thể thêm những context ít liên quan.

Confidence: Cao.

Prediction 3: không chắc chắn làm chất lượng tốt hơn.

Reason: Dimension lớn giúp model có khả năng biểu diễn thông tin hơn, nhưng cũng cần nhiều dữ liệu và chi phí tính toán hơn. Nếu corpus không đủ lớn, việc tăng dimension có thể không cải thiện được chất lượng embedding.

Confidence: Cao.

- Prediction 4: "doctor" và "physician" không chắc chắn sẽ có similarity cao vì nếu corpus chỉ có 100 câu.

Reason: Word embedding phụ thuộc vào ngữ cảnh xuất hiện các từ trong corpus. Nếu corpus chỉ có 100 câu, dù hiện cả từ "doctor" và "physician" xuất hiện nhiều lần trong các context tương tự. Vì vậy model có thể chưa được học mối quan hệ ngữ nghĩa giữa hai từ một cách tốt nhất.

Confidence: Cao.

16. Skip Bài tập Prediction.

* C Bow : Ta có $[cat] \rightarrow the$

$[the, eat] \rightarrow cat$

$[cat, fish] \rightarrow eat s$

~~Skip-gram~~ $[eat s] \rightarrow fish$

* Skip-gram : $the \rightarrow cat$

$cat \rightarrow the$

$cat \rightarrow eat s$

$eat s \rightarrow cat$

$eat s \rightarrow fish$

$fish \rightarrow eat s.$

23. Bài tập tính analogy:

king - man + we man

$$= [8, 2, 7] - [5, 1, 5] + [5, 3, 5]$$

$$= [8, 4, 7]$$

$\Rightarrow$ vector mới đại diện cho một từ có quan hệ king với "king" tương tự như quan hệ giữa "we man" và "man" như là "queen". Đây là một ví dụ về g pattern quan hệ trong không gian embedding.

26. Từ "bank" có thể mang nhiều ý nghĩa, chẳng hạn "ngân hàng" trong ngữ cảnh tài chính hay là "bờ sông" trong ngữ cảnh địa lý. Tuy nhiên word2vec chỉ tạo 1 vector duy nhất cho mỗi từ. Vì vậy, vector của "bank" phải tổng hợp thông tin từ nhiều ngữ cảnh và không thể biểu diễn riêng biệt từng nghĩa của từ.

=> Đây là một hạn chế của static embeddings