Thứ
Ngày . . No.

6. Bài tập tính toán

Bài 1. $z = w^T x + b$

$= 0,5 \cdot 1 + (-0,2) \cdot 2 + 0,4 \cdot 0 + 0,1$

$= 0,2$

$\sigma(z) = \frac{1}{1+e^{-z}}$

$\sigma(0,2) = \frac{1}{1+e^{-0,2}} = 0,5498$

Vậy $P(y=1|x) = 0,5498$

7. Bài 2 - ~~Three~~

TH: $r = 0,5$

Vì $0,72 > 0,5$

→ model dự đoán class 1

TH: $r = 0,8$

Vì $0,72 < 0,8$

→ model dự đoán class 0

Trả lời: * Nếu tăng threshold, model sẽ khó dự đoán positive hơn.

- Số dự đoán positive giảm
- Thường precision tăng vì model chỉ chọn case mà nó tự tin hơn
- Nhưng recall có thể giảm vì nhiều positive thật bị bỏ sót.

* Nếu giảm threshold, model dễ dự đoán positive hơn.

- Số dự đoán positive tăng
- Thường recall tăng vì bắt được nhiều positive hơn
- Nhưng precision có thể giảm vì dễ kéo theo nhiều false positive hơn.

Scanned with CamScanner

8. Bai 3 - Confusion Matrix.

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{80}{80+10} = \frac{80}{90}$$

$$= 0,8889.$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{80}{80+20} = 0,8$$

$$F1 = \frac{2PR}{P+R} = \frac{2.0,8889.0,8}{0,8889+0,8}$$

$$= 0,8421$$

~~$= 84,21\%$~~

Nếu đây là bài toán phát hiện spam.

False positive là email bình thường nhưng bị dự đoán nhầm thành spam

False Negative là email spam nhưng bị dự đoán nhầm thành email thường.

9. Bai 4.

Model đạt accuracy 95% nhưng chưa thể kết luận là model tốt.

Nguyên nhân là dataset bị mất cân bằng: có 950 mẫu negative và chỉ 50 mẫu positive. Model dự đoán tất cả là negative nên chỉ đạt accuracy cao, nhưng không phát hiện được bất kỳ mẫu positive nào.

Vì vậy cần xem thêm các metric như precision, recall và F1, đặc biệt là đối với class positive, thay vì chỉ dựa vào accuracy

Thứ
Ngày . . No.

10. Prediction trước experiment.

Prediction 1.

+ Prediction: Tôi dự đoán TF-IDF + logistic Regression có khả năng hoạt động tốt, nhưng phụ thuộc vào dataset và bài toán.

+ Reason: TF-IDF giữ được thông tin về các từ đặc trưng trong văn bản. Với những bài toán mà một số từ hoặc cụm từ có khả năng phân biệt class rõ, logistic Regression có thể học được các feature này để classification.

Confidence: khá cao

Prediction 2:

+ Prediction: Average Word2Vec không chắc chắn tốt hơn TF-IDF

+ Reason: Average Word2Vec có thể biểu diễn quan hệ ngữ nghĩa giữa các từ, nhưng việc lấy trung bình các word embeddings có thể làm mất word order và một số từ quan trọng trong câu. TF-IDF giữ thông tin từ và tầm rõ hơn, nên representation nào tốt hơn còn phụ thuộc vào dataset và bài toán.

+ Confidence: Cao

Prediction 3:

Prediction: Tăng vocabulary size không chắc làm accuracy tăng

Reason: Vocabulary lớn hơn giúp giữ được nhiều từ hơn, nhưng cũng có thể thêm các từ hiếm hoặc ít liên quan. Điều này làm feature space lớn hơn nhưng ko đảm bảo các feature mới đều hữu ích cho classification.

Confidence: Cao

Thứ
Ngày . . No.

Prediction 4:

Prediction: Bỏ stopwords không chắc chắn làm performance tăng.

Reason: Một số stopwords có thể không mang nhiều thông tin phân loại, nhưng một số từ như "not" có thể ảnh hưởng nhiều đến nghĩa của câu. Nếu loại bỏ những từ như vậy, model có thể mất thông tin quan trọng.

Confidence: Cao

Prediction 5.

Prediction: accuracy và F1 có thể cho kết luận khác nhau.

Reason. Với dataset mất cân bằng, model có thể đạt accuracy cao bằng dự đoán tốt ca class chiếm đa số nhưng lại bỏ sót nhiều mẫu class thiểu số. F1 kết hợp precision và recall nên phản ánh tốt hơn khả năng dự đoán của model trong trường hợp này.

Confidence: Cao

Scanned with CamScanner