Calculations

9. Calculations Exercise 1 - MLM loss

Chỉ có 1 vị trí bị mask. Token đúng là "cats" xs gán cho token này là 0,7

$$L = -\ln P(\text{cats} \mid \text{ctx}) = -\ln(0,7) = 0,3567$$

1. Nếu xác suất là 0,95:

$$L = -\ln(0,95) = 0,0513.$$

loss giảm vì model gán xs cao hơn cho token đúng.

2. Nếu xs là là 0,1

$$L = -\ln(0,01) = 4,6052.$$

3. loss giảm mạnh vì model gán xs cao hơn cho token đúng.

3. Vì sao cross-entropy phù hợp với MLM?

Tại vị trí mask, model chọn token đúng cho toàn vocabulary. Cross-entropy đo mức model gán xác suất cho token đó, xác suất càng cao thì loss càng thấp. Các phép tính nên dùng logarithm tự nhiên.

10. Calculation Exercise 2 - Tokenization

Câu "the cats are playing ". được tokenizer của

Token	ID	Special token	Attention mask
[CLS]	2	1	1
_the	14	0	1
_cats	9471	0	1
_are	50	0	1
_playing	791	0	1
.	9	0	1
[SEP]	3	1	1

- Token sequence: [CLS], _the, _cats, _are, _playing, ., [SEP].
- Token IDs: [2, 14, 9471, 50, 791, 9, 3].
- Attention mask: [1, 1, 1, 1, 1, 1, 1], vì không có padding
- Có 9 words nếu đếm theo không rõng, 7 token nếu tính special, 5 context subword tokens nếu bỏ special tokens và tính cả dấu câu.
- Bốn từ đầu được biểu diễn bằng một piece, dấu chấm là token riêng, không có continuation piece

HONG HA

Scanned with CamScanner

trong từ trong lí dụ này.

Dấu "_" thể hiện rằng giữa các từ trong tokenized sequence Pico. :)

LUYỆN NÉT CHỮ
Nên nết người
HONG HA
Scanned with CamScanner